

RELATÓRIO TÉCNICO: PRÉ-PROCESSAMENTO TEXTUAL DE COMENTÁRIOS DE JOGADORES

Autor: Daniel Augusto Mandira

Instituição: Faculdade de Tecnologia de Registro – FATEC

Curso: Desenvolvimento de Software Multiplataforma (DSM 6)

1. INTRODUÇÃO

Este relatório apresenta a implementação de um sistema experimental de pré-processamento textual desenvolvido em linguagem Python. O estudo de caso foca no tratamento de dados não estruturados provenientes de avaliações do jogo *Lords of the Fallen*. O objetivo central é a transformação de registros ruidosos — caracterizados por gírias e abreviações — em uma base de dados estruturada, viabilizando a extração de *insights* e a aplicação de técnicas de mineração de texto para a compreensão das demandas da comunidade de usuários.

2. FUNDAMENTAÇÃO TEÓRICA

O Processamento de Linguagem Natural (PLN) é uma subárea da inteligência artificial que visa a interação entre computadores e a linguagem humana. O pré-processamento é a etapa inicial de um *pipeline* de PLN, composta pelas seguintes técnicas:

- **Tokenização:** processo de segmentação do texto em unidades mínimas denominadas *tokens*;
- **Remoção de Stopwords:** eliminação de termos com alta frequência gramatical, mas baixo valor semântico (ex.: artigos e preposições);
- **Radicalização (Stemming):** método heurístico que reduz a palavra ao seu radical através do corte de afixos;

- **Lematização:** análise morfológica que reduz a palavra à sua forma canônica ou lema (infinitivo para verbos, masculino singular para substantivos).

3. DESENVOLVIMENTO

3. DESENVOLVIMENTO

A análise foi desenvolvida utilizando a linguagem *Python*, empregando as bibliotecas *Pandas* para manipulação de dados, e *NLTK* (*Natural Language Toolkit*) e *spaCy* para as rotinas de PLN. A base de dados utilizada, *metacritic_reviews.csv*, contém registros coletados da plataforma *Metacritic*.

O fluxo de trabalho foi estruturado nas seguintes etapas:

1. Padronização de caixa (minúsculas) e limpeza de caracteres especiais;
2. Tokenização de sentenças via método *word_tokenize*;
3. Filtragem de *stopwords* baseada no *corpus* da língua portuguesa;
4. Extração de radicais pelo algoritmo *SnowballStemmer*;
5. Lematização via modelo linguístico *pt_core_news_sm*.

4. RESULTADOS

A execução do algoritmo obteve êxito ao converter frases completas e desestruturadas em listas organizadas de palavras com relevância semântica.

Abaixo, demonstra-se um exemplo de transformação obtida pelo sistema:

Texto Original: "o novo update quebrou o jogo inteiro, crasha toda hora"

Tokens: ['o', 'novo', 'update', 'quebrou', 'o', 'jogo', 'inteiro', 'crasha', 'toda', 'hora']

Remoção de Stopwords: ['novo', 'update', 'quebrou', 'jogo', 'inteiro', 'crasha', 'toda', 'hora']

Radicalização (Stemming): ['nov', 'updat', 'quebr', 'jog', 'inteir', 'crash', 'tod', 'hor']

Lematização: ['novo', 'update', 'quebrar', 'jogo', 'inteiro', 'crasha', 'todo', 'hora']

Observa-se que a lematização preservou o significado das palavras de forma compreensível (como converter "quebrou" para "quebrar"), ao passo que o processo de "stemming" produziu raízes linguísticas que muitas vezes não formam palavras válidas (exemplo: "quebr"). Termos em inglês próprios de jogos (como "update" e "crasha") apresentaram desafios naturais para bibliotecas em português, no entanto, o pipeline conseguiu isolá-los perfeitamente, permitindo futuras customizações de dicionário.

5. CONCLUSÃO

O estudo demonstrou que o pré-processamento é indispensável para a redução da dimensionalidade e eliminação de ruídos em bases de dados textuais. Observou-se que a lematização apresentou resultados superiores na preservação do sentido semântico em comparação ao *stemming*, embora apresente maior custo computacional.

As principais dificuldades encontradas relacionam-se ao vocabulário específico do nicho de jogos eletrônicos (*jargões*), o que sugere a necessidade de futuras implementações de dicionários léxicos customizados. Conclui-se que a estruturação desses dados permite às empresas do setor identificar problemas recorrentes de forma automatizada, fundamentando decisões estratégicas para a melhoria da experiência do usuário e otimização do produto.